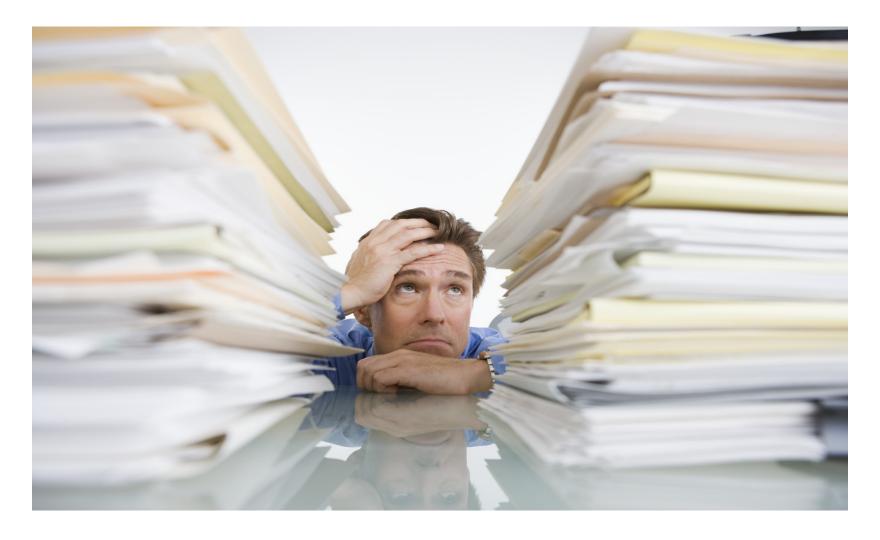
# Data Science, Machine Learning and Big Data

Fabrício J. Barth

Professor da Faculdade BandTec Cientísta de Dados da VAGAS Tecnologia

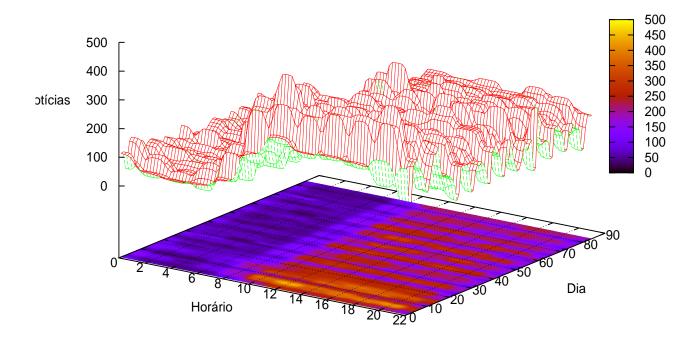
#### Problema



http://investing caffeine.com/2010/01/07/tmi-the-age-of-information-overload/

## Alguns dados...

Relação Horário x Dia x Quantidade de Notícias Produzidas



Quantidade de notícias publicadas na Web por apenas seis veículos brasileiros de notícias ( $D_0=17/07/2007$ )

#### Dados mais atuais

- A380: Heathrow  $\rightarrow$  JFK: 640 TBs de log
- Twitter: 12+ TBs of tweet every day
- Facebook: 25+ TBs of log data every day
- Sistemas baseados em RFID
- Smartphones com GPS, acelerómetro, ...

http://www.ibmbigdatahub.com/ Mitchell. Mining our reality. Science. 2009

#### De onde vem os dados?



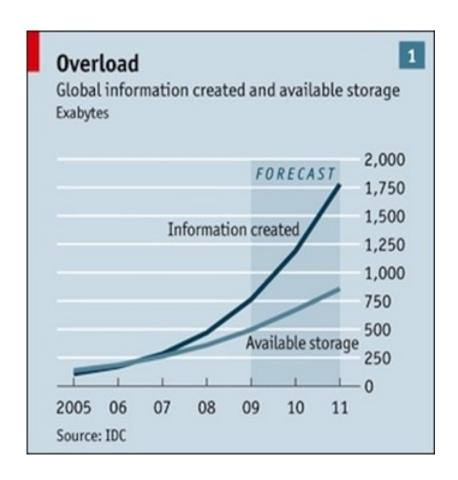
Summer School on Big Data - EMC

## Mining our reality



Mitchell. Mining our reality. Science. 2009

#### Big Data



"We collect an astonishing amount of digital information... ...we've long since surpassed our ability to store and process it all. Big data is here, and it's causing big problems..."[1]


#### Big Data é um conceito relativo

- O que é **grande hoje**...
- Pode não ser grande amanhã...

#### Big Data refers to...

- All data that comes at high Volume
- All data that comes at high Velocity
- All data that comes from a Variety of Sources (structured + unstructured data)

#### Variety of sources



The Digital Universe Is Growing By 7,600 PB / Day

Summer School on Big Data - EMC

## Por que manipular este tipo de dado?

- Identificar comportamento anômalo (i.e., fraudes, falhas)
- Sumarizar tendências de publicações de artigos e patentes sobre um determinado tema.
- Sumarizar e filtrar notícias relevantes.

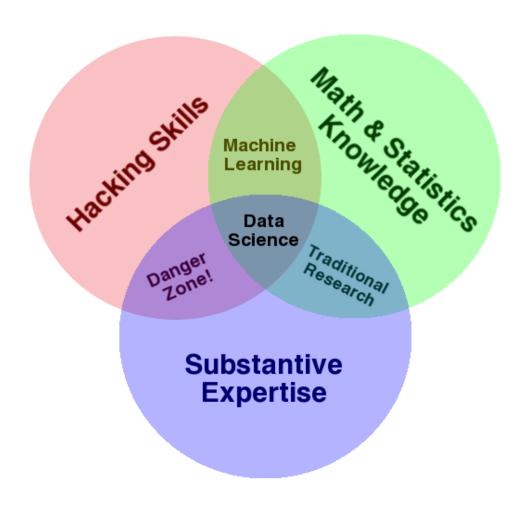
- Sumarizar a opinião expressa na Web sobre a sua empresa.
- Identificar padrões de navegação em sites.
- Identificar conteúdo impróprio em sites.
- Recomendação de livros, filmes, restaurantes e empregos.

#### Data Scientist

- Data Scientist: The Sexiest Job of the 21st Century.

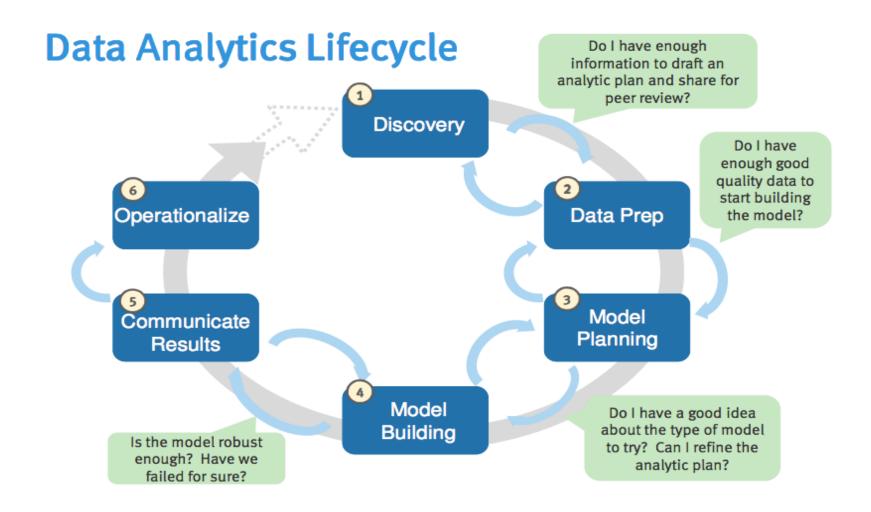
  Harvard Business Review.
- Data Scientist applies advanced analytical tools and algorithms to generate predictive insights and new product innovations that are a direct result of the data.

## Data Science Venn Diagram



http://www.drewconway.com/zia/?p=2378

## Ciclo típico de um projeto



Summer School on Big Data

#### References

[1] Data, data everywhere. a special report on managing information. *The Economist*, pages 1–16, February 2010.